

LAPORAN TEKNIS KOMPREHENSIF

BAB 1: PROBLEM DISCOVERY & PENDAHULUAN

1.1 Latar Belakang Masalah

Indonesia merupakan negara agraris yang menjadikan padi sebagai komoditas pangan utama sehingga produktivitasnya berperan penting dalam menjaga ketahanan pangan nasional. Namun, berdasarkan data Badan Pusat Statistik (BPS), produksi padi Indonesia pada tahun 2024 mengalami penurunan sebesar 1,55% dibandingkan tahun sebelumnya, dari 53,98 juta ton menjadi 53,14 juta ton Gabah Kering Giling (BPS, 2025). Kondisi ini menunjukkan bahwa sektor pertanian padi masih menghadapi berbagai tantangan yang dapat mempengaruhi ketersediaan pangan nasional.

Salah satu tantangan tersebut adalah serangan penyakit tanaman, khususnya Tungro, Blast, dan Brown Spot. Penyakit Blast dapat menyebabkan kehilangan hasil panen hingga 30% setiap tahun dan mencapai 100% pada kondisi serangan berat (Asibi et al., 2019). Sementara itu, penyakit Tungro dan Brown Spot juga diketahui dapat menurunkan produktivitas padi secara signifikan apabila tidak terdeteksi dan ditangani sejak dini. Serangan penyakit yang terlambat ditangani berpotensi menurunkan produktivitas lahan serta meningkatkan kerugian ekonomi petani.

Di lapangan, identifikasi penyakit padi masih banyak dilakukan secara manual melalui pengamatan visual oleh petani maupun penyuluh pertanian. Metode ini sangat bergantung pada pengalaman pengamat dan rentan terhadap kesalahan karena beberapa penyakit memiliki gejala yang serupa, sehingga diagnosis yang terlambat atau kurang tepat dapat menghambat penanganan serta meningkatkan risiko penyebaran penyakit ke area pertanian yang lebih luas (Sarker et al., 2021). Permasalahan tersebut menunjukkan perlunya suatu pendekatan yang mampu membantu proses identifikasi penyakit padi secara lebih cepat, akurat, dan mudah diakses agar tindakan pengendalian dapat dilakukan sedini mungkin untuk meminimalkan risiko kehilangan hasil panen.

1.2 Solusi Utama

Untuk mengatasi permasalahan identifikasi penyakit padi, tim kami mengembangkan RiceCare AI, sebuah sistem deteksi penyakit daun padi berbasis *Deep Learning* menggunakan arsitektur MobileNetV2. Sistem ini memungkinkan petani mengunggah foto daun padi melalui aplikasi web, kemudian secara otomatis mengklasifikasikan penyakit tungro, blast, atau brown spot beserta *confidence score* sebagai indikator tingkat keyakinan prediksi.

Selain menampilkan hasil deteksi, RiceCare AI juga menyediakan informasi mengenai karakteristik penyakit disertai rekomendasi penanganan awal yang dapat dilakukan petani. Nilai inovasi utama sistem ini terletak pada integrasi antara deteksi penyakit berbasis AI dan penyajian informasi praktis dalam satu platform yang mudah digunakan. Dengan demikian, petani tidak hanya memperoleh diagnosis yang cepat dan akurat, tetapi juga rekomendasi penanganan yang tepat.

1.3 Pertanyaan Bisnis (Business Questions)

1. Bagaimana distribusi jumlah sampel antar kelas penyakit pada dataset, dan apakah terdapat ketidakseimbangan kelas yang berpotensi mempengaruhi performa model klasifikasi?
2. Bagaimana perbandingan distribusi data train sebelum dan sesudah proses augmentasi?
3. Bagaimana karakteristik visual gambar daun padi pada masing-masing kelas penyakit?
4. Bagaimana distribusi rata-rata nilai RGB pada setiap kelas penyakit?

BAB 2: DATA WRANGLING & PERSIAPAN DATA

2.1 Data Gathering (Pengumpulan Data)

Dataset yang digunakan dalam proyek ini berasal dari beberapa dataset publik yang tersedia di platform Kaggle. Data berupa citra daun padi dengan kategori penyakit tungro, blast, brown spot, dan kondisi sehat dikumpulkan dari berbagai kontributor dan repositori penelitian. Untuk meningkatkan keberagaman data, beberapa dataset digabungkan dan melalui proses kurasi guna memastikan kesesuaian label serta kualitas gambar yang digunakan dalam pelatihan model. Sumber dataset yang digunakan dalam proyek ini adalah sebagai berikut:

Tabel 2.1 Sumber Dataset Proyek

No	Nama Dataset	Sumber
1	Rice Disease Dataset	Kaggle
2	Rice Leaf Disease Dataset	Kaggle
3	Rice Leaf Diseases Dataset	Kaggle
4	Rice Leaf Disease Detection Dataset	Kaggle
5	Zambali Rice Dataset (Public V1)	Kaggle
6	Dataset of Leaf Disease and Pets of Agricultural Plants	Kaggle
7	FIRE Dataset	Kaggle
8	PlantVillage Dataset	Kaggle
9	Image captioning dataset, random images	Kaggle
10	Vehicle dataset - Images & Segmentation	Kaggle

2.2 Data Assessing (Penilaian Kualitas Data)

Pada tahap *assessing data*, dilakukan evaluasi terhadap kualitas dan karakteristik dataset citra daun padi untuk memastikan data layak digunakan dalam proses pelatihan model. Analisis dilakukan pada beberapa aspek utama, yaitu distribusi jumlah citra tiap kelas, ukuran citra, mode warna, format file dan

duplikasi citra. Pemeriksaan distribusi citra per kelas bertujuan untuk mengidentifikasi potensi ketidakseimbangan data (*class imbalance*) yang dapat menyebabkan model lebih cenderung mengenali kelas tertentu dibandingkan kelas lainnya.

Tabel 2.2 Distribusi Citra per Kelas

No	Kelas	Jumlah
1	Blast	2.587
2	Brown Spot	3.293
3	Tungro	2.352
4	Sehat	2.597
5	Unknown	2.683

Berdasarkan Tabel 2.2, jumlah citra pada setiap kelas menunjukkan distribusi yang relatif seimbang. Kelas brown spot memiliki jumlah citra terbanyak, sedangkan kelas tungro memiliki jumlah citra paling sedikit. Namun, perbedaan jumlah data antar kelas tidak terlalu signifikan sehingga risiko terjadinya bias model akibat ketidakseimbangan data (*class imbalance*) tergolong rendah. Selain itu, dilakukan analisis ukuran citra dengan menghitung statistik dimensi gambar, seperti nilai minimum, maksimum, rata-rata, dan median. Analisis ukuran citra dilakukan untuk mengetahui variasi dimensi gambar dalam dataset.

Tabel 2.3 Statistik Ukuran Citra

Statistik	Width (px)	Height (px)
Minimum	122,00	160,00
Maksimum	5.760,00	4.032,00
Rata - rata	780,65	693,74
Median	332,00	300,00

Berdasarkan Tabel 2.3, ukuran citra menunjukkan variasi yang cukup besar sehingga diperlukan proses *resizing* agar seluruh gambar memiliki dimensi input yang seragam. Pemeriksaan mode warna dilakukan untuk memastikan konsistensi jumlah kanal warna pada seluruh citra yang akan digunakan sebagai input model.

Tabel 2.4 Distribusi Mode Warna

Mode Warna	Jumlah
RGB	13.450
RGBA	42
L	18
P	2
Total	13.512

Hasil analisis menunjukkan bahwa sebagian besar gambar menggunakan mode RGB, yaitu sebanyak 13.450 citra (99,54%). Selain itu, ditemukan 42 citra dengan mode RGBA, 18 citra dengan mode L (*grayscale*), dan 2 citra dengan mode P (*palette*). Berdasarkan hasil tersebut, dataset memiliki konsistensi mode warna yang sangat baik karena mayoritas citra telah menggunakan format RGB. Namun, untuk memastikan keseragaman data masukan pada model MobileNetV2, seluruh citra dengan mode RGBA, L, dan P dikonversi ke format RGB pada tahap preprocessing. Pemeriksaan format file juga dilakukan untuk mengetahui proporsi file berformat JPG, JPEG, dan PNG serta mengidentifikasi kemungkinan adanya format yang tidak sesuai atau berpotensi menimbulkan masalah pada tahap pemrosesan data.

Tabel 2.5 Distribusi Format File

Format File	Jumlah
JPEG	13.360
PNG	151
GIF	1
Total	13.512

Hasil pemeriksaan menunjukkan bahwa sebagian besar citra menggunakan format JPEG, yaitu sebanyak 13.360 file (98,88%). Selain itu, terdapat 151 file berformat PNG dan 1 file berformat GIF. Berdasarkan hasil analisis, dataset didominasi oleh format JPEG sehingga menunjukkan tingkat konsistensi yang baik. Meskipun demikian, masih terdapat sejumlah kecil file PNG dan GIF. Oleh karena

itu, seluruh citra perlu distandarisasi ke format yang seragam selama tahap preprocessing untuk memastikan kompatibilitas dan konsistensi data yang digunakan dalam pelatihan model. Analisis duplikasi dilakukan untuk mengidentifikasi keberadaan citra yang sama atau sangat mirip dalam dataset. Keberadaan data duplikat dapat menyebabkan bias selama proses pelatihan karena model berpotensi mempelajari informasi yang berulang sehingga performa evaluasi menjadi kurang representatif.

Tabel 2.6 Hasil Pemeriksaan Duplikasi Data

Keterangan	Jumlah
Total citra	13.512
Citra duplikat	2.252
Citra unik	11.260

Hasil pemeriksaan menunjukkan terdapat 2.252 citra duplikat. Oleh karena itu, citra tersebut dihapus pada tahap data cleaning untuk menghindari bias selama proses pelatihan model. Hasil *assessing data* menunjukkan bahwa dataset memiliki distribusi kelas yang relatif seimbang dan mayoritas citra telah menggunakan mode warna RGB serta format file JPEG. Namun, masih ditemukan variasi ukuran citra, perbedaan mode warna, keberagaman format file, serta beberapa data duplikat yang perlu ditangani sebelum proses pelatihan model.

Tabel 2.7 Ringkasan Temuan dan *Preprocessing* yang Diperlukan

Temuan	<i>Preprocessing</i> yang diperlukan
Distribusi kelas relatif seimbang	Tidak diperlukan penanganan khusus terhadap <i>class imbalance</i> ; data augmentation diterapkan untuk meningkatkan keragaman data latih
Variasi ukuran citra	<i>Resizing</i> menjadi 224×224 piksel
Terdapat beberapa format file (JPEG, PNG, GIF)	Konversi dan standarisasi seluruh citra ke format JPEG
Terdapat citra dengan mode RGBA, L, dan P	Konversi seluruh citra ke RGB
Ditemukan data duplikat	Penghapusan citra duplikat

2.3 Data Cleaning (Pembersihan Data)

Berdasarkan hasil data assessing pada poin 2.2, ditemukan beberapa permasalahan kualitas data yang perlu ditangani sebelum dataset dapat digunakan untuk pelatihan model. Proses pembersihan data dilakukan melalui tiga tahapan berikut.

2.3.1 Konversi Mode Warna, Format File, dan Standarisasi Ukuran Gambar

Seluruh proses konversi dilakukan dengan menyalin data dari folder `rice_leaf_disease_images/` ke folder baru `rice_leaf_disease_images_clean/` agar data mentah asli tetap tersimpan dan tidak tertimpa. Dari 13.512 gambar yang diproses, sebanyak 10.636 gambar mengalami konversi dan 2.876 gambar tidak memerlukan perubahan. Konversi mencakup tiga hal, yaitu seluruh gambar bermode non-RGB (RGBA, L, P) dikonversi ke mode RGB agar kompatibel dengan input arsitektur MobileNetV2 yang membutuhkan 3 channel warna. Kedua, gambar berformat PNG dan GIF dikonversi ke format JPEG agar konsisten dengan keseluruhan dataset. Ketiga, seluruh gambar distandarisasi ukurannya menjadi 224×224 piksel sesuai kebutuhan input MobileNetV2, mengingat ukuran gambar sebelumnya sangat bervariasi dari 122×160 hingga 5760×4032 piksel. Hasil verifikasi setelah konversi menunjukkan seluruh 13.512 gambar telah berhasil distandarisasi..

2.3.2 Penghapusan Data Duplikat

Deteksi duplikat dilakukan menggunakan metode hashing MD5 pada setiap file gambar. Pendekatan ini membandingkan nilai hash antar gambar dalam satu kelas sehingga gambar yang identik secara konten dapat teridentifikasi meskipun memiliki nama file yang berbeda. Hasil deteksi menunjukkan terdapat duplikat yang tersebar di beberapa kelas, sehingga setelah proses penghapusan jumlah total dataset berkurang dari 13.512 menjadi 11.260 gambar dengan rincian sebagai berikut.

2.4 Data Dictionary (Kamus Data)

Nama Fitur / Kolom	Tipe Data	Deskripsi Keterangan
label	object	Kelas daun padi yang menjadi target prediksi model
filename	object	Nama gambar yang tersimpan dalam penyimpanan
width dan height	Integer	Lebar dan tinggi dimensi gambar dalam satuan piksel (224 x 224).
mode warna	Object	Warna piksel yang digunakan (RGB)
format gambar	Object	Format gambar untuk training model (JPEG)


BAB 3: EXPLORATORY DATA ANALYSIS (EDA) & EXPLANATORY ANALYSIS

3.1 Exploratory & Explanatory Data Analysis

Tahap Exploratory Data Analysis (EDA) dilakukan untuk mengeksplorasi dan memahami karakteristik dataset secara mendalam melalui visualisasi data. Analisis ini bertujuan untuk menjawab pertanyaan bisnis yang telah dirumuskan pada Bab 1, mencakup distribusi kelas dataset, perbandingan distribusi data train sebelum dan sesudah augmentasi, karakteristik visual gambar per kelas, serta distribusi nilai RGB antar kelas penyakit.


Pertanyaan Bisnis 1: Bagaimana distribusi jumlah sampel antar kelas penyakit pada dataset, dan apakah terdapat ketidakseimbangan kelas yang berpotensi memengaruhi performa model klasifikasi?

Setelah melakukan scraping dan cleaning data pada dataset gambar kelas per kelas, dibuat perbandingan antara sebelum dan setelah cleaning data yang disajikan pada grafik di bawah ini.



Gambar 1 Grafik distribusi gathering dan setelah cleaning

Proses pengumpulan data dari berbagai sumber di Kaggle menghasilkan total 13.512 gambar yang terdistribusi ke dalam lima kelas. Setelah dilakukan proses assessing dan cleaning yang mencakup pemeriksaan data korup, penghapusan duplikasi, konversi ukuran gambar, mode warna, dan format file untuk menyesuaikan kebutuhan model MobileNetV2, jumlah dataset bersih yang tersisa menjadi 11.260 gambar. Pengurangan sebesar 2.252 gambar ini seluruhnya berasal dari penghapusan data duplikat yang teridentifikasi pada tahap cleaning.




Gambar 2 Grafik pembagian dataset train dan test

Dataset bersih kemudian dibagi dengan rasio 80% untuk data train dan 20% untuk data test. Data train berjumlah 8.860 gambar digunakan untuk melatih model dalam mengenali pola penyakit, sedangkan data test berjumlah 2.254 gambar digunakan untuk mengevaluasi performa model pada data yang belum pernah dilihat sebelumnya. Jika dilihat dari grafik, distribusi jumlah sampel antar kelas pada data train menunjukkan adanya ketidakseimbangan. Kelas Unknown memiliki jumlah sampel terbanyak dengan 2.146 gambar, sedangkan kelas Blast memiliki jumlah tersedikit dengan 1.559 gambar. Apabila ketidakseimbangan ini tidak ditangani, model berpotensi lebih condong memprediksi kelas dengan jumlah data yang lebih banyak sehingga dapat menurunkan akurasi klasifikasi pada kelas minoritas. Oleh karena itu, diperlukan proses penyeimbangan data sebelum pelatihan model.

Pertanyaan Bisnis 2: Bagaimana perbandingan distribusi data train sebelum dan sesudah proses augmentasi?

Mengatasi ketidakseimbangan kelas yang ditemukan pada pertanyaan bisnis pertama, memerlukan proses pembersihan data lanjutan menggunakan augmentasi dan penyeimbangan pada data train dengan target 2.000 gambar per kelas. Teknik augmentasi yang diterapkan meliputi rotasi searah dan berlawanan jarum jam, flip horizontal dan vertikal, penyesuaian brightness dan contrast, serta blur. Khusus untuk kelas Unknown yang jumlahnya melebihi target, dilakukan pengurangan data secara acak hingga mencapai 2.000 gambar. Perbandingan distribusi data train sebelum dan sesudah augmentasi disajikan pada gambar di

bawah.




Gambar 3 Distribusi data train sebelum dan sesudah augmentasi

Setelah proses augmentasi dan penyeimbangan, seluruh kelas pada data train berhasil diseragamkan menjadi 2.000 gambar per kelas sehingga total data train menjadi 10.000 gambar. Proses ini hanya diterapkan pada data train dan tidak pada data test. Hal ini bertujuan agar data test tetap merepresentasikan kondisi nyata dataset yang dikumpulkan sehingga evaluasi model dapat dilakukan secara objektif dan tidak bias.


Pertanyaan Bisnis 3: Bagaimana karakteristik visual gambar daun padi pada masing-masing kelas penyakit?

Karakteristik visual ditinjau menggunakan pendekatan gambar tipikal, yaitu gambar asli dari dataset yang paling merepresentasikan karakteristik tiap kelas. Pemilihan gambar tipikal didasarkan pada kedekatan jarak piksel setiap gambar terhadap rata-rata piksel kelasnya menggunakan perhitungan jarak Euclidean, sehingga gambar yang dipilih merupakan foto yang secara visual paling mewakili karakteristik umum kelasnya. Berdasarkan hasil visualisasi, ditemukan karakteristik visual yang khas pada masing-masing kelas sebagaimana dirangkum pada gambar di bawah ini.



Gambar 4 Gambar tipikal per kelas

Selain gambar tipikal, dilakukan pula visualisasi sampel gambar acak sebanyak lima gambar per kelas dari data train. Visualisasi ini bertujuan untuk memberikan gambaran yang lebih luas mengenai keragaman kondisi visual gambar dalam setiap kelas, mengingat satu gambar tipikal saja belum cukup untuk merepresentasikan variasi gambar yang ada.




Gambar 5 Visualisasi sampel per kelas secara acak

Dari visualisasi sampel tersebut, terlihat bahwa meskipun gambar dalam satu kelas memiliki karakteristik yang serupa, terdapat variasi kondisi pencahayaan, sudut pengambilan gambar, dan latar belakang yang cukup beragam. Keberagaman ini diharapkan dapat membantu model dalam mengenali pola penyakit pada berbagai kondisi visual yang berbeda di lapangan.

Pertanyaan Bisnis 4: Bagaimana distribusi rata-rata nilai RGB pada setiap kelas penyakit?

Distribusi nilai RGB dilakukan untuk memahami karakteristik warna piksel pada masing-masing kelas penyakit. Analisis ini dilakukan terhadap empat kelas

penyakit, yaitu Blast, Brown Spot, Healthy, dan Tungro, dengan mengecualikan kelas Unknown karena tidak memiliki ciri visual yang spesifik dan representatif sebagai kelas penyakit daun padi. Rata-rata nilai RGB dihitung dari 200 sampel gambar per kelas yang diambil dari folder dataset bersih.



Gambar 6 Grafik distribusi rata-rata nilai RGB per kelas penyakit daun padi

Berdasarkan hasil visualisasi, kelas Healthy memiliki nilai channel Green (G) yang paling tinggi dibandingkan kelas penyakit lainnya. Hal ini secara visual mencerminkan warna daun yang lebih hijau dan segar sebagaimana kondisi daun padi yang tidak terinfeksi penyakit. Sebaliknya, kelas penyakit seperti Blast, Brown Spot, dan Tungro cenderung memiliki nilai Red (R) yang lebih dominan, yang mencerminkan adanya perubahan warna daun akibat infeksi patogen berupa munculnya bercak coklat maupun perubahan warna daun menjadi kuning. Perbedaan karakteristik nilai RGB antar kelas ini menunjukkan bahwa informasi warna piksel dapat menjadi fitur pembeda yang signifikan dalam proses klasifikasi.

BAB 4: FEATURE ENGINEERING

4.1 Feature Engineering

Feature engineering pada proyek RiceCare AI difokuskan pada proses rekayasa data gambar untuk menangani ketidakseimbangan kelas (class imbalance) yang ditemukan pada tahap EDA. Pendekatan yang digunakan adalah augmentasi data, yaitu teknik menghasilkan gambar baru secara sintetis dari gambar yang sudah ada dengan menerapkan berbagai transformasi visual. Selain augmentasi, dilakukan pula pengurangan data pada kelas yang melebihi target. Kedua proses ini hanya diterapkan pada data train dan tidak pada data test.

4.1.2 Teknik Augmentasi yang Diterapkan

Delapan fungsi transformasi dikembangkan menggunakan library TensorFlow untuk menghasilkan variasi gambar baru dari gambar asli yang sudah ada. Seluruh fungsi augmentasi memastikan ukuran gambar tetap pada dimensi 224×224 piksel sesuai standar input MobileNetV2. Rincian setiap teknik augmentasi yang digunakan disajikan pada tabel 4.1.

Tabel 4.1 Teknik augmentasi

No	Teknik Augmentasi	Fungsi	Parameter
1	Rotate Anticlockwise	Memutar gambar 90 derajat berlawanan arah jarum jam	k=1 (rotasi 90°)
2	Rotate Clockwise	Memutar gambar 90 derajat searah jarum jam	k=3 (rotasi 270°)
3	Flip Up Down	Membalik gambar secara vertikal (atas menjadi bawah)	-
4	Flip Left Right	Membalik gambar secara horizontal (kiri menjadi kanan)	-
5	Add Brightness	Menambah kecerahan gambar secara acak	delta: 0,1 – 0,3
6	Adjust Contrast	Mengubah kontras gambar secara acak	factor: 0,8 – 1,5

7	Adjust Saturation	Mengubah saturasi warna gambar secara acak	factor: 0,8 – 1,5
8	Blur Image	Menghaluskan gambar menggunakan Gaussian blur	kernel 3×3kernel: [[1,2,1],[2,4,2],[1,2,1]]

Teknik rotasi dan flip digunakan untuk mensimulasikan variasi sudut pengambilan gambar daun di lapangan yang dapat berbeda-beda tergantung posisi petani saat memotret. Teknik penyesuaian brightness, contrast, dan saturation digunakan untuk mensimulasikan variasi kondisi pencahayaan saat pengambilan gambar, mengingat foto lapangan dapat diambil dalam kondisi siang terik, mendung, maupun di bawah naungan. Teknik blur digunakan untuk mensimulasikan variasi kualitas kamera yang digunakan petani, sehingga model diharapkan tetap mampu mengklasifikasikan penyakit meskipun gambar yang diunggah kurang tajam.

4.2 Proses Augmentasi dan Penyeimbangan Data

Proses augmentasi dilakukan dengan menetapkan target sebesar 2.000 gambar untuk setiap kelas pada data train. Setiap iterasi augmentasi, satu gambar sumber dipilih secara acak dari kelas yang sama, kemudian satu teknik transformasi dipilih secara acak dari delapan teknik yang tersedia dan diterapkan pada gambar tersebut. Hasil augmentasi disimpan dengan nama awalan `aug_` pada nama file agar mudah dibedakan dari gambar asli. Proses ini diulang hingga jumlah gambar pada kelas tersebut mencapai target 2.000 gambar. Khusus untuk kelas Unknown yang jumlahnya sudah melebihi target (2.146 gambar), dilakukan pengurangan data secara acak sebanyak 146 gambar menggunakan metode random sampling tanpa pengembalian. Pendekatan acak dipilih agar proses pengurangan tidak menimbulkan bias terhadap gambar tertentu dalam kelas tersebut. Hasil akhir proses augmentasi dan penyeimbangan data disajikan pada Tabel 4.2 berikut.

Tabel 4.2 Hasil augmentasi dan penyeimbangan pada data train

No	Kelas	Sebelum	Sesudah	Keterangan
----	-------	---------	---------	------------

1	Blast	1.559	2.000	+441 gambar hasil augmentasi
2	Brown Spot	1.714	2.000	+286 gambar hasil augmentasi
3	Healthy	1.804	2.000	+196 gambar hasil augmentasi
4	Tungro	1.783	2.000	+217 gambar hasil augmentasi
5	Unknown	2.146	2.000	-146 gambar dihapus secara acak

BAB 5: PENGEMBANGAN DASHBOARD INTERAKTIF & DEPLOYMENT

5.1 Desain Komponen Dashboard

Dashboard EDA RiceCare AI dikembangkan menggunakan layout wide pada Streamlit untuk memaksimalkan ruang tampilan data secara horizontal. Secara keseluruhan, dashboard terbagi menjadi tiga halaman utama yang dapat diakses melalui radio button pada sidebar di sisi kiri layar.

Halaman 1: Overview & Data Dictionary, menyajikan ringkasan umum proyek yang mencakup metric card berisi jumlah kelas, total data train, total data test, dan total keseluruhan gambar. Terdapat expander interaktif yang memuat daftar sumber dataset dari Kaggle, tabel data dictionary yang menjelaskan setiap atribut dataset, serta penjelasan karakteristik masing-masing kelas penyakit daun padi.

Halaman 2: Explore & Explain Data, merupakan halaman utama analisis yang terdiri dari lima section berurutan. Section pertama menampilkan distribusi dataset dilengkapi dengan dropdown filter untuk beralih antara kondisi sebelum dan sesudah data cleaning. Setiap pergantian pilihan pada dropdown akan memperbarui donut chart interaktif beserta metric card yang menampilkan jumlah data per kelas secara dinamis. Section kedua menampilkan grouped bar chart perbandingan jumlah data train dan test per kelas. Section ketiga menyediakan dropdown filter untuk membandingkan distribusi data train sebelum dan sesudah augmentasi, di mana bar chart dan tabel ringkasan akan diperbarui secara otomatis sesuai pilihan yang dipilih. Section keempat menampilkan gambar tipikal per kelas yang dipilih berdasarkan pendekatan jarak Euclidean terdekat terhadap rata-rata piksel kelasnya. Section kelima menampilkan grouped bar chart distribusi rata-rata nilai piksel RGB per kelas penyakit.

Halaman 3: Image Samples, menyediakan dua filter interaktif berupa selectbox untuk memilih kelas penyakit yang ingin ditampilkan dan selectbox untuk menentukan jumlah sampel gambar yang ingin dilihat, dengan rentang pilihan antara 1 hingga 10 gambar. Gambar ditampilkan secara acak dari data train dalam layout grid maksimal empat kolom per baris.

Seluruh visualisasi pada dashboard menggunakan skema warna yang sama untuk setiap kelas, yaitu oranye untuk Blast, coklat untuk Brown Spot, hijau untuk Healthy, kuning untuk Tungro, dan abu-abu untuk Unknown. Hal ini diterapkan pada seluruh chart, judul, dan elemen antarmuka di ketiga halaman agar pembaca dapat mengidentifikasi setiap kelas tanpa perlu membaca keterangan secara berulang.

5.2 Pengembangan via Streamlit & Deployment

Dashboard dikembangkan menggunakan bahasa pemrograman Python dengan memanfaatkan pustaka Streamlit untuk menyajikan hasil analisis data secara interaktif. Proses pengembangan dilakukan pada lingkungan lokal dengan mengintegrasikan berbagai pustaka analisis dan visualisasi data yang diperlukan. Seluruh dependensi yang digunakan dalam pengembangan didokumentasikan pada berkas *requirements.txt* untuk memastikan aplikasi dapat dijalankan pada lingkungan yang berbeda dengan konfigurasi yang konsisten.

Setelah proses pengembangan selesai, kode sumber dashboard beserta berkas pendukung diunggah ke repositori GitHub. Repositori tersebut kemudian dihubungkan dengan platform Streamlit Cloud untuk proses deployment. Streamlit Cloud secara otomatis mengambil kode dari GitHub, menginstal seluruh dependensi yang tercantum dalam *requirements.txt*, dan menjalankan aplikasi sesuai file utama yang ditentukan.

Hasil deployment berupa dashboard berbasis web yang dapat diakses melalui URL publik menggunakan peramban tanpa memerlukan instalasi perangkat lunak tambahan. Dashboard ini memungkinkan pemangku kepentingan untuk mengeksplorasi hasil analisis data, melihat visualisasi, serta memperoleh insight yang relevan secara interaktif melalui satu platform terpusat.

BAB 6: KESIMPULAN & SARAN

6.1 Kesimpulan

Berdasarkan hasil proses pengumpulan, pembersihan, eksplorasi, dan persiapan data, diperoleh beberapa temuan utama yang menjawab seluruh pertanyaan bisnis yang diajukan.

1. **Distribusi jumlah sampel antar kelas penyakit menunjukkan adanya ketidakseimbangan kelas (class imbalance).** Setelah proses cleaning, dataset bersih berjumlah 11.260 gambar yang terbagi ke dalam lima kelas penyakit. Pada data train, jumlah sampel antar kelas tidak merata, dengan kelas Unknown memiliki jumlah sampel terbanyak (2.146 gambar) dan kelas Blast memiliki jumlah sampel paling sedikit (1.559 gambar). Ketidakseimbangan ini berpotensi menyebabkan model lebih bias terhadap kelas mayoritas sehingga menurunkan kemampuan klasifikasi pada kelas dengan jumlah data yang lebih sedikit.
2. **Proses augmentasi berhasil menyeimbangkan distribusi data train.** Untuk mengatasi ketidakseimbangan kelas, dilakukan augmentasi data dan penyesuaian jumlah sampel hingga setiap kelas memiliki 2.000 gambar. Hasilnya, seluruh kelas pada data train memiliki distribusi yang seimbang dengan total 10.000 gambar. Kondisi ini diharapkan dapat membantu model mempelajari karakteristik setiap kelas secara lebih proporsional dan meningkatkan performa klasifikasi. Sementara itu, data test tetap dipertahankan dalam kondisi asli agar evaluasi model mencerminkan kondisi nyata dan menghasilkan pengukuran performa yang objektif.
3. **Setiap kelas penyakit memiliki karakteristik visual yang berbeda dan dapat digunakan sebagai dasar proses klasifikasi.** Analisis gambar tipikal dan visualisasi sampel gambar menunjukkan bahwa masing-masing kelas memiliki pola visual yang khas. Meskipun terdapat variasi pencahayaan, sudut pengambilan gambar, dan latar belakang, ciri-ciri utama penyakit tetap dapat diamati pada setiap kelas. Temuan ini menunjukkan bahwa dataset memiliki informasi visual yang cukup untuk mendukung proses pembelajaran model dalam membedakan jenis penyakit daun padi.
4. **Distribusi rata-rata nilai RGB menunjukkan perbedaan karakteristik warna antar kelas penyakit.** Kelas Healthy memiliki nilai kanal Green (G) tertinggi yang merepresentasikan warna hijau daun yang sehat. Sebaliknya,

kelas Blast, Brown Spot, dan Tungro menunjukkan dominasi nilai kanal Red (R) yang lebih tinggi akibat perubahan warna daun yang disebabkan oleh infeksi penyakit. Hasil ini membuktikan bahwa informasi warna merupakan fitur yang relevan dan berpotensi menjadi pembeda penting dalam proses klasifikasi penyakit daun padi.

Secara keseluruhan, hasil analisis menunjukkan bahwa dataset telah berhasil dibersihkan, diseimbangkan, dan memiliki karakteristik visual yang cukup berbeda antar kelas. Kondisi tersebut memberikan dasar yang baik untuk proses pelatihan model MobileNetV2 dalam melakukan klasifikasi penyakit daun padi secara efektif.

6.2 Saran

Berdasarkan hasil analisis yang telah dilakukan, beberapa saran yang dapat diberikan adalah sebagai berikut:

1. Menambahkan dataset dari sumber yang lebih beragam dan valid, seperti institusi penelitian atau sumber resmi lainnya, agar kualitas dan representativitas data semakin baik.
2. Menggunakan data lapangan sebagai data pembandingan untuk menguji performa model pada kondisi nyata sehingga hasil klasifikasi menjadi lebih relevan dan dapat diandalkan.
3. Menambah jumlah serta variasi data pada setiap kelas penyakit untuk membantu model mempelajari pola yang lebih beragam dan meningkatkan kemampuan generalisasi.
4. Melakukan pengembangan model dan eksplorasi teknik preprocessing maupun augmentasi yang lebih lanjut untuk meningkatkan akurasi klasifikasi penyakit daun padi.

REFERENSI & LAMPIRAN

Asibi, A. E., Chai, Q., & Coulter, J. A. (2019). *Rice Blast: A Disease with Implications for Global Food Security*. *Agronomy*, 9(8), 451.

<https://doi.org/10.3390/agronomy9080451>

Badan Pusat Statistik Indonesia. (3 Februari 2025). *Pada 2024, luas panen padi mencapai sekitar 10,05 juta hektare dengan produksi padi sebanyak 53,14 juta ton gabah kering giling (GKG)*.

<https://www.bps.go.id/id/pressrelease/2025/02/03/2414/pada-2024--luas->

Al Mamun, M. A., Karim, S. R. I., Sarkar, M. I., & Alam, M. Z. (2024). Evaluating The Efficacy Of Hybrid Deep Learning Models In Rice Variety Classification. *International Journal of Advanced Research and Interdisciplinary Scientific Endeavours*, 1(1), 34-52.

<https://doi.org/10.61359/11.2206-2404>

Link google collab :  Dataset_RiceCareAI.ipynb

Dashboard : <https://dashboard-capstone-ricecareai.streamlit.app/>